Evolución Histórica de la NBA

Un análisis profundo del perfil atlético y su impacto en el baloncesto moderno.

Data Source

DATA ANALYTICS

Nuestro Equipo de Expertos

Impulsando el análisis de datos para entender el baloncesto del futuro.

David Cornejo
Data Engineer

Juan Alvarado
BI Developer

Lucas Alamanni
Data Analyst

Julian Uribe
Business Analyst

Objetivo del Proyecto: Evolución de la NBA

Analizar datos históricos de la NBA para identificar cómo ha evolucionado el perfil físico y atlético de los jugadores a lo largo del tiempo. Buscamos entender la relación de estos cambios con las dinámicas de juego, estrategias y la popularidad del deporte.

> ¿Cómo ha cambiado el "jugador ideal" de la NBA a lo largo de las décadas y qué implicaciones tiene esto para el futuro?

Hitos Clave del Proyecto

Actividad	Inicio	Fin	Duración	28 MIÉ	29 JUE	30 VIE	31 SÁB	1 DOM	2 LUN	3 MAR	4 MIÉ	5 JUE	6 VIE	7 SÁB	8 DOM	9 LUN	10 MAR	11 MIÉ	12 JUE	13 VIE
Crear y compartir el repositorio público de Github	28/1/2026	29/1/2026	1																	
Identificar los archivos a usar y armar la estructura en carpetas de Github	29/1/2026	30/1/2026	1																	
Crear la base de datos en Big Query en base a un D-E-R.	2/2/2026	3/2/2026	1																	
Seleccionar las tablas que se van a utilizar y objetos necesarios de SQL	4/2/2026	5/2/2026	1																	
Flujo de importación de datos	5/2/2026	6/2/2026	1																	
Corroborar el acceso de todos los miembros a la base de datos	6/2/2026	7/2/2026	1																	
Buscar nuevo informacion que complemente nuestra BD (en formato .csv)	9/2/2026	10/2/2026	1																	
EDA Inicial	10/2/2026	12/2/2026	2																	
ETL inicial	10/2/2026	12/2/2026	2																	
Crear métodos de automatización de ingesta de datos nuevos.	10/2/2026	12/2/2026	2																	

1 Fase 1: Recopilación y Exploración de Datos

Del 28 de enero al 12 de febrero de 2026.

2 Fase 2: Limpieza y Transformación de Datos

Asegurar la calidad y preparación de los datos.

3 Fase 3: Análisis y Modelado

4 Fase 4: Visualización y Presentación

Creación de informes y la presentación final.

Stack Tecnológico

Herramientas clave para un análisis de datos robusto y eficiente

kaggle

Plataforma líder para ciencia de datos y datasets públicos.

HENRY

Recurso educativo y fuente de datos para aprendizaje práctico.

Python

Lenguaje principal para manipulación, análisis y modelado de datos. Se utilizan librerias como **Numpy**, **Pandas** y **Matplotlib.**

GitHub

Plataforma para control de versiones y colaboración esencial.

Google Cloud

Infraestructura en la nube para despliegue y gestión de recursos.

BigQuery

Data warehouse escalable de Google Cloud para grandes volúmenes de datos.

Power BI

Herramienta de Microsoft para visualizaciones interactivas y dashboard.

Limpieza y Transformación con Python

La calidad de los datos es fundamental. Hemos implementado rigurosos procesos de limpieza y transformación utilizando Python para asegurar la fiabilidad de nuestro análisis.

```python
import os
import pandas as pd

resultados = {}
#busca los campos NA en cada tabla
for ruta_csv in csv_files:
    df = pd.read_csv(ruta_csv)

    na_por_columna = df.isna().sum()

    nombre_archivo = os.path.basename(ruta_csv)

    resultados[nombre_archivo] = na_por_columna.to_frame(
        name="cantidad_NA"
    )
```

✓ 3m 27.5s Python

```python
from IPython.display import display

for archivo, df_na in resultados.items():
    print(f"\n📄 {archivo}")
    display(df_na)
```

✓ 0.2s

draft_history.csv

	cantidad_NA
person_id	0
player_name	0
season	0
round_number	0
round_pick	0
overall_pick	0
draft_type	0
team_id	0
team_city	0
team_name	0
team_abbreviation	0
organization	19
organization_type	19
player_profile_flag	0

Identificación de Nulos (NA)

Detectamos valores nulos en cada tabla para entender la completitud y proceder con su imputación o eliminación.

Resultado de Detección

Obtenemos una visión clara de las columnas que requieren atención para garantizar la integridad del conjunto de datos.

Descubriendo Patrones en los Datos

```python
import os
import pandas as pd
from IPython.display import display

# Diccionario para guardar resultados
resultados_duplicados = {}

for ruta_csv in csv_files:
    df = pd.read_csv(ruta_csv)

    # Contar duplicados por columna
    duplicados_por_columna = {col: df[col].duplicated(keep=False).sum() for col in df.columns}

    # Convertir a DataFrame (igual que hiciste con los NA)
    nombre_archivo = os.path.basename(ruta_csv)
    resultados_duplicados[nombre_archivo] = pd.DataFrame.from_dict(
        duplicados_por_columna, orient="index", columns=["cantidad_duplicados"]
    )

# Mostrar resultados
for archivo, df_dup in resultados_duplicados.items():
    print(f"\n📄 {archivo}")
    display(df_dup)
```

Se realizan tablas para identificar valores duplicados por cada CSV

game_info.csv

	cantidad_duplicados
game_id	80
game_date	55907
attendance	51826
game_time	58013

Visualización obtenida

Descubriendo Patrones en los Datos

Antes del modelado, realizamos un análisis exploratorio para entender la distribución, relaciones y anomalías en los datos.

```python
import matplotlib.pyplot as plt

archivos = list(total_na_por_csv.keys())
totales_na = list(total_na_por_csv.values())

plt.figure(figsize=(12, 6))
plt.bar(archivos, totales_na, color="steelblue")

plt.yscale("log")  # ← escala logarítmica
plt.title("Cantidad total de valores NA por CSV (escala log)")
plt.xlabel("Archivo CSV")
plt.ylabel("Total de NA (log)")
plt.xticks(rotation=45, ha="right")
plt.tight_layout()
plt.show()
```

Se realiza una grafica para identificar cual es el CSV con mas NA

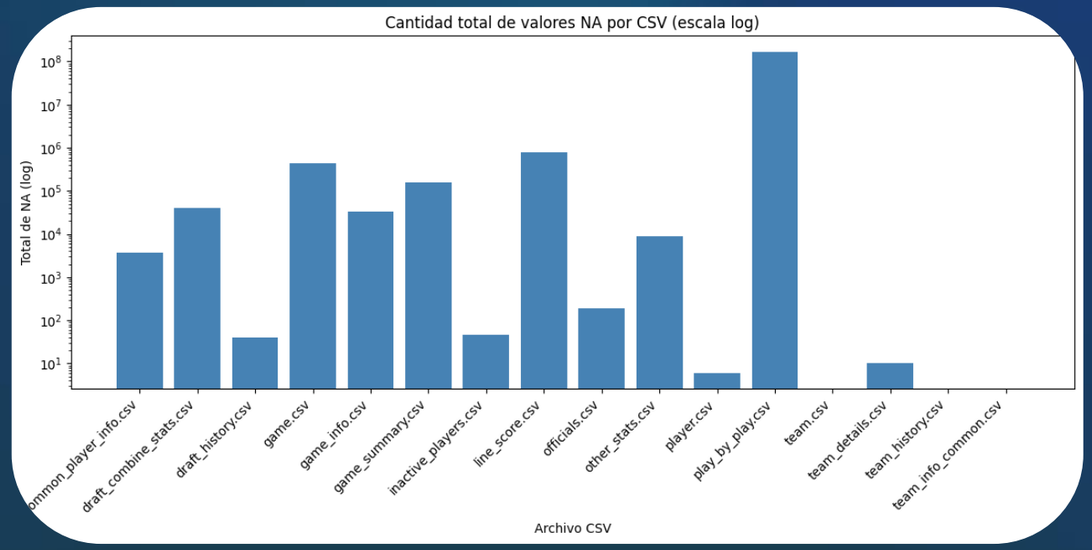

Visualización obtenida

Análisis Descriptivo Detallado

```python
import pandas as pd
import os

carpeta = r"C:\Users\lucas\OneDrive\Escritorio\Csv de nba"
na_vals = ["NA", "N/A", "null", "NULL", ""]

# Listar todos los CSV
csv_files = [os.path.join(carpeta, f) for f in os.listdir(carpeta) if f.endswith(".csv")]

# Diccionario para guardar resultados
resumen_por_csv = {}

for ruta_csv in csv_files:
    df = pd.read_csv(ruta_csv, na_values=na_vals)
    nombre_archivo = os.path.basename(ruta_csv)

    # 1 Seleccionar columnas numéricas
    num_cols = df.select_dtypes(include=["number"]).columns

    # 2 Excluir dummies (solo 0 y 1)
    num_cols_no_dummies = [
        col for col in num_cols
        if not df[col].dropna().isin([0,1]).all()
    ]

    # 3 Excluir columnas con "id" o "year" en el nombre
    num_cols_final = [
        col for col in num_cols_no_dummies
        if ("id" not in col.lower()) and ("year" not in col.lower())
    ]

    # 4 Crear DataFrame resumen
    resumen = pd.DataFrame(index=num_cols_final)
    if num_cols_final:  # solo si hay columnas para procesar
        resumen["media"] = df[num_cols_final].mean()
        resumen["mediana"] = df[num_cols_final].median()
        resumen["moda"] = df[num_cols_final].mode().iloc[0]
        resumen["desviacion_estandar"] = df[num_cols_final].std()
    else:
        resumen["media"] = []
        resumen["mediana"] = []
        resumen["moda"] = []
        resumen["desviacion_estandar"] = []

    # Guardar en diccionario
    resumen_por_csv[nombre_archivo] = resumen

    # Mostrar resumen de este CSV
    print(f"\n===== Resumen de {nombre_archivo} =====")
    display(resumen)
```

Visualizamos la distribución de datos para identificar tendencias y comportamientos atípicos en las estadísticas de los jugadores.

```
===== Resumen de draft_combine_stats.csv =====
```

	media	mediana	moda	desviacion_estandar
season	2011.251072	2011.00	2022.00	7.201710
height_wo_shoes	77.600444	77.75	76.50	3.356327
height_w_shoes	78.788963	79.00	80.50	3.301766
weight	215.391672	213.60	198.00	26.276537
wingspan	82.402286	82.50	82.00	4.006972
standing_reach	103.508990	104.00	103.50	4.878400
body_fat_pct	7.529169	6.70	6.70	2.933166
hand_length	8.716031	8.75	8.50	0.470688
standing_vertical_leap	29.254835	29.00	28.50	3.099532
max_vertical_leap	34.521490	34.50	33.00	3.704144
lane_agility_time	11.413857	11.35	11.21	0.598113
modified_lane_agility_time	3.088173	3.10	3.10	0.220015
three_quarter_sprint	3.280497	3.27	3.20	0.133918
bench_press	10.314155	10.00	13.00	5.541429

Tabla resumen de media, mediana, moda y desviación estándar por característica numérica, para una vista rápida de la distribución de datos.

Actualización de Datos: Eficiencia y Fiabilidad

Nuestra solución de automatización mantiene el dataset actualizado. Vea el proceso en el siguiente video.

Proceso de Carga Automática

Este video ilustra la carga automática de datos desde Google Drive, asegurando información actualizada y minimizando la intervención manual para un análisis eficiente.

Ver Video de Automatización

Aplicación de técnicas estadísticas y predictivas.

Dashboard Interactivo en Power BI

Transformamos datos complejos en visualizaciones claras e intuitivas para facilitar decisiones estratégicas. A continuación, se muestran los mockups del dashboard diseñado.

Dashboard Interactivo en Power BI

Visual general de los jugadores

Dashboard Interactivo en Power BI

Análisis en el tiempo de los Jugadores